KUMULUS

Documentação Técnica da Solução

Assistente Inteligente de Consulta ao Catálogo

Cliente: Rodavale Distribuidora de Autopeças Ltda.

Plataforma: Microsoft Foundry

Versão do documento: 2.0

Público: Equipe técnica e responsáveis pela sustentação

Assistente Inteligente de Consulta ao Catálogo

Cliente: Rodavale Distribuidora de Autopeças Ltda. Plataforma: Microsoft Foundry Versão do documento: 2.0 Público: Equipe técnica e responsáveis pela sustentação

Documento técnico de referência. Complementa a Proposta Comercial 2026-014 (revisão 2).

1. Visão Geral

Este documento descreve a arquitetura, os componentes e as decisões técnicas da solução de assistente conversacional construída para o televendas da Rodavale. Destina-se à equipe de sustentação e a qualquer profissional que precise operar, auditar ou evoluir a solução.

A solução é uma arquitetura multiagente: um agente orquestrador classifica a pergunta do vendedor e um fluxo visual encaminha a solicitação para o especialista adequado. Toda resposta é derivada de consulta às bases de conhecimento — não há geração de conteúdo sem lastro.

O que mudou em relação à versão 1.0. A primeira versão era um agente único que consultava um banco Azure SQL através de um servidor MCP hospedado em Azure Container Apps. A versão atual atende ao requisito de configuração sem código: os três agentes, suas bases de conhecimento e o roteamento entre eles são definidos inteiramente no portal do Microsoft Foundry. A seção 9 registra o que se ganhou e o que se perdeu nessa troca.

1.1 Componentes

Componente	Serviço	Responsabilidade
Orquestrador	Foundry Agent Service	Classifica a solicitação e devolve a rota
Especialista de Catálogo e Estoque	Foundry Agent Service	Compatibilidade, SKU, marca, preço-base e saldo
Especialista Comercial	Foundry Agent Service	Cliente, tabela de preço, desconto e cotação indicativa
Modelo	Foundry Models — GPT-5-mini	Compreensão de linguagem natural nos três agentes
Conhecimento	File Search do Foundry	Indexação e busca nos arquivos de conhecimento
Orquestração	Workflow do Foundry (Preview)	Roteamento condicional entre os agentes

1.2 Ambiente

Projeto Foundry `rafaeltomiazi-0258`, grupo de recursos `rg-rafael-tomiazi`, região `eastus` (por disponibilidade de modelos). Nesta configuração não há banco de dados nem serviço de integração provisionado: as bases de conhecimento são arquivos indexados pela própria plataforma.

2. Arquitetura

2.1 Desenho do fluxo

2.2 Como o roteamento funciona

O orquestrador não chama os especialistas. Ele apenas classifica a pergunta e responde em formato fixo:

```
ROTA: CATALOGO

CONTEXTO: resumo objetivo dos dados informados pelo vendedor
```

A resposta é gravada na variável `rota_orquestrador` do workflow. O nó de condição lê essa variável e decide o caminho. Quem executa o encaminhamento é o fluxo, não o modelo.

Essa é uma diferença importante em relação ao recurso Connected Agents, que existia no portal clássico e permitia que o próprio modelo decidisse a delegação. Esse recurso não está disponível no Foundry atual (ver seção 10). A consequência prática é positiva para auditoria: o caminho percorrido é explícito, visível no diagrama e verificável no rastreamento de cada execução.

2.3 Expressões de condição

As condições usam Power Fx. A variável que guarda a saída do agente é uma tabela de mensagens, e não um texto simples, o que exige selecionar a coluna e pegar a última mensagem:

```
StartsWith(Last(ShowColumns(Local.rota_orquestrador, Text)).Text, "ROTA: CATALOGO")
StartsWith(Last(ShowColumns(Local.rota_orquestrador, Text)).Text, "ROTA: COTACAO")
StartsWith(Last(ShowColumns(Local.rota_orquestrador, Text)).Text, "ROTA: COMERCIAL")
```

O caminho `Else` não tem condição: ele atende tanto solicitações fora do escopo quanto qualquer resposta do orquestrador que não siga o formato esperado.

2.4 Configuração dos nós

Nó	Agente	Entrada	Saída salva em
1	orquestrador-rodavale	`System.LastMessageText`	`rota_orquestrador`
CATALOGO	especialista-catalogo-estoque-rodavale	`rota_orquestrador`	—
COTACAO (1º)	especialista-catalogo-estoque-rodavale	`rota_orquestrador`	`resposta_catalogo`
COTACAO (2º)	especialista-comercial-rodavale	`resposta_catalogo`	—
COMERCIAL	especialista-comercial-rodavale	`rota_orquestrador`	—
Else	Deliver a message	—	—

Todos os nós de agente usam `System.ConversationId` como contexto de conversa. Por isso os agentes compartilham o mesmo histórico, o que permite que uma pergunta incompleta seja complementada na mensagem seguinte sem perder o contexto.

3. Bases de Conhecimento

As bases são arquivos Markdown indexados pelo File Search do Foundry, no índice `indice-catalogo-estoque-rodavale` (catálogo) e no índice do agente comercial.

Arquivo	Tamanho	Conteúdo	Agente
`catalogo_estoque_rodavale.md`	1,2 MB	3.367 aplicações veiculares, com montadora, modelo, motorização, faixa de anos, SKU, peça, marca, categoria, posição, preço-base e estoque por filial	Catálogo e Estoque
`indice_skus_rodavale.md`	58 KB	Índice compacto por SKU, com descrição, marca, categoria, posição, preço-base e estoque	Catálogo e Estoque
`clientes_precos_rodavale.md`	11 KB	90 clientes, tabela de preço atribuída e 24 regras de desconto por categoria	Comercial

3.1 Por que existem dois arquivos de catálogo

O arquivo grande responde bem a perguntas por veículo, porque as linhas de um mesmo modelo ficam próximas e a busca por trecho recupera o bloco certo. Ele falhou, porém, ao procurar um SKU isolado dentro de 3.367 linhas: a consulta pelo RV-1002 não retornava resultado, e a cotação quebrava.

O índice compacto resolve esse caso. Ele contém uma linha por SKU, o que torna a recuperação confiável. A instrução do agente define qual arquivo consultar em cada situação: índice de SKUs quando o vendedor

informa um código, catálogo completo quando a pergunta é por veículo.

3.2 Convenções de preenchimento

- `Ano final` igual a **9999** indica veículo em linha; a aplicação é considerada vigente.
- `Motor` igual a **TODAS** indica que a peça atende todas as versões daquele modelo.
- Os dados representam uma posição de referência em **20/08/2026**. Não há atualização em tempo real, reserva ou confirmação de entrega.

3.3 Fórmula de precificação

```
preco_final = preco_base × (1 - desconto_percentual / 100)
```

O desconto é determinado pelo cruzamento entre a tabela de preço do cliente (A, B ou C) e a categoria do produto.

3.4 Preparação dos dados de demonstração

Os dados da Rodavale são fictícios e foram gerados por script (`database/gerar_dados.py`), assim como os arquivos de conhecimento, extraídos desse mesmo conjunto. Essa preparação é anterior à solução e não faz parte dela: nenhum código é executado durante o atendimento. Em um cenário real, os arquivos seriam produzidos a partir da extração do ERP.

4. Configuração dos Agentes

4.1 Modelo

Foi selecionado o GPT-5-mini para os três agentes. A tarefa envolve interpretação de linguagem, busca em arquivo e formatação de resposta — não exige raciocínio complexo. Modelos de maior capacidade elevariam o custo por consulta sem ganho mensurável neste caso de uso.

Registro de compatibilidade: o modelo `gpt-6-astra` foi testado e não suporta a ferramenta File Search no portal, o que motivou a escolha do `gpt-5-mini`.

4.2 Orquestrador

Diretriz	Objetivo
Responder somente com ROTA e CONTEXTO	Produzir uma saída que o fluxo consiga interpretar
Nunca responder à pergunta do vendedor	Impedir que o orquestrador opine sobre peça, preço ou qualquer assunto geral
Usar apenas fatos informados pelo vendedor	Evitar que ele inclua no contexto dados que não possui, como preço ou estoque
Classificar fora do escopo explicitamente	Garantir que assuntos alheios ao televendas sigam pelo caminho padrão

Este agente não tem ferramentas nem arquivos. É deliberado: ele só classifica.

4.3 Especialista de Catálogo e Estoque

Diretriz	Objetivo
Consultar o arquivo antes de responder	Impedir resposta gerada sem lastro
Aplicar todos os filtros	Ano dentro da faixa, motorização igual à pedida ou TODAS, posição e tipo de peça correspondentes
Apresentar até dez opções	Evitar omitir alternativas válidas quando há muitas compatíveis
Consultar o índice quando houver SKU	Tornar a busca por código determinística
Entregar apenas o handoff técnico na rota de cotação	Impedir que ele localize cliente, aplique desconto ou calcule preço final
Não oferecer reserva, pedido ou disponibilidade atual	Manter a resposta coerente com o caráter datado da base

4.4 Especialista Comercial

Diretriz	Objetivo
Consultar o arquivo antes de responder	Impedir resposta gerada sem lastro
Localizar o cliente por código, nome fantasia ou razão social	Cobrir as formas como o vendedor se refere ao cliente
Gerar a cotação a partir do handoff do Catálogo	Usar preço-base e categoria recebidos, sem redescobrir a peça
Considerar quantidade igual a uma unidade	Evitar pergunta desnecessária quando o vendedor não informa quantidade
Não confirmar compatibilidade ou estoque	Manter a fronteira com o domínio do Catálogo
Escrever valores monetários entre crases	Contornar uma limitação de renderização descrita na seção 9

4.5 Manutenção

Ajuste de comportamento não exige nova implantação. As instruções são editadas no portal e passam a valer na interação seguinte. O mesmo vale para o roteamento: incluir um novo domínio significa criar um agente, acrescentar uma rota no orquestrador e um caminho no fluxo.

5. Validação

Bateria executada no Preview do workflow, com gabarito extraído das bases.

#	Pergunta	Resultado esperado	Status
1	Quais pastilhas de freio dianteiras servem no Chevrolet Onix 2018 1.4?	RV-1001, RV-1002, RV-1004, RV-1005 e RV-1006, sem o RV-1003 (motor 1.0)	Aprovado
2	Qual é a tabela de preço da Auto Center Central?	Cliente CLI-0008, tabela A	Aprovado

#	Pergunta	Resultado esperado	Status
3	Faça uma cotação da RV-1002 para a Auto Center Central	Preço-base R$ 79,77, desconto de 19,63%, preço final R$ 64,11	Aprovado
4	Qual é a previsão do tempo para amanhã?	Mensagem padrão de fora de escopo	Aprovado
5	"Preciso de amortecedor", depois "Onix 2016 1.4, dianteiro"	RV-1037, RV-1038 e RV-1040, sem o RV-1041 (válido até 2015) e sem os traseiros	Aprovado
6	Quais pastilhas servem numa Kia Sportage 2020?	Informar que não encontrou, sem sugerir peça	Aprovado

Os testes 1, 5 e 6 verificam a precisão da busca em arquivo, que era o principal risco técnico da arquitetura sem banco de dados. O teste 5 verifica a preservação de contexto entre mensagens. O teste 3 verifica o encadeamento entre os dois especialistas.

6. Operação

6.1 Atualização do conhecimento

A carga é manual: gera-se o arquivo atualizado e envia-se ao índice do agente pelo portal, em Tools, Upload files. O índice aceita novos arquivos sem recriar o agente. A automação dessa sincronização está prevista como evolução.

6.2 Inclusão de um novo domínio

1. Criar o agente especialista com sua instrução e, se houver, seu arquivo de conhecimento. 2. Acrescentar a rota correspondente nas instruções do orquestrador. 3. Adicionar um caminho no nó de condição, com a expressão Power Fx da nova rota. 4. Ligar o caminho ao novo agente e salvar o workflow, que gera uma nova versão.

6.3 Monitoramento

O que observar	Onde
Caminho percorrido em cada execução	Traces do workflow no portal
Erros de expressão ou de nó	Mensagem de falha na execução do workflow
Trecho de arquivo usado em cada resposta	Citações exibidas na resposta do agente
Consumo de tokens e custo	Painel de uso do projeto Foundry

6.4 Versionamento

Cada Save do workflow cria uma versão imutável, acessível pelo seletor de versões. A versão validada nos testes descritos na seção 5 é a **versão 4** do workflow `televendas-rodavale`.

7. Segurança

Sem alteração de dados. Os agentes apenas consultam arquivos indexados. Não há gravação, nem caminho técnico para alterar cadastro, estoque ou preço.

Escopo restrito por instrução. Cada especialista responde somente dentro do seu domínio, e o caminho padrão trata qualquer assunto fora do televendas com mensagem fixa.

Sem credenciais na solução. Não há cadeia de conexão, chave de API ou segredo envolvido na configuração atual, uma vez que não existe serviço externo conectado.

Rastreabilidade. A plataforma registra cada execução do fluxo, os agentes acionados e as citações usadas na resposta.

Ponto de atenção. As bases de conhecimento contêm dados comerciais de clientes, incluindo tabelas de preço e descontos. O controle de acesso é o do próprio projeto Foundry: quem tem acesso ao projeto tem acesso às respostas. Em produção, o acesso deve ser restrito à equipe de televendas.

8. Infraestrutura da versão 1.0

Os recursos da primeira versão continuam provisionados e **não fazem parte da solução atual**:

Recurso	Nome	Grupo de recursos	Situação
Azure SQL Database	`rodavale` em `sql-rodavale-rafael`	`rg-rafael-foundry`	Ativo, fora da solução
Azure Container App	`ca-rodavale-mcp`	`rg-rafael-foundry`	Ativo, fora da solução
Azure Container Registry	imagem do Data API Builder	`rg-rafael-foundry`	Ativo, fora da solução

Decisão pendente: desligar esses recursos para encerrar o custo, ou mantê-los como base da evolução descrita na seção 11, que restabelece a consulta ao dado vigente. Enquanto a decisão não é tomada, eles continuam gerando custo sem uso.

Os artefatos dessa versão permanecem no repositório (`database/`, `integracao/`) como registro técnico.

9. Limitações Conhecidas

Limitação	Impacto	Encaminhamento
Base é uma posição datada de 20/08/2026	Estoque e preço podem divergir do ERP	Sincronização automatizada (seção 11)
Busca por trecho em arquivo grande	Falhou ao procurar SKU isolado no catálogo completo	Resolvido com o índice compacto de SKUs; novos casos podem exigir índices semelhantes
Limite de dez opções por resposta	Consultas com muitas peças compatíveis exibem apenas as dez primeiras	O agente oferece refinamento por marca, filial ou faixa de preço
A linha ROTA e CONTEXTO aparece no chat	O vendedor vê a classificação antes da resposta	Comportamento da plataforma, pois os agentes compartilham a conversa. Na demonstração, ajuda a evidenciar o roteamento

Limitação	Impacto	Encaminhamento
Renderização de valores monetários	O Preview interpretava $ como fórmula matemática e quebrava o texto	Contornado com instrução para escrever valores entre crases
Sem controle de acesso por perfil	Qualquer usuário do projeto vê dados comerciais de clientes	Restrição de acesso ao projeto em produção
Bases indexadas na região East US	Não há residência de dados no Brasil nesta configuração. Os dados da prova de conceito são fictícios	Provisionamento em Brazil South na implantação produtiva
Base de demonstração é amostra do catálogo	Cobertura parcial de veículos e peças	Carga completa na implantação

10. Prazos da Plataforma

Dois anúncios da Microsoft afetam a longevidade desta arquitetura e foram considerados na escolha:

Recurso	Retirada anunciada	Efeito
Workflows do Foundry	01/12/2026	O roteamento visual usado nesta solução deixa de ser suportado no portal
Agentes e portal clássicos, onde existia o Connected Agents	31/03/2027	Não é alternativa de longo prazo

O caminho indicado pela Microsoft para orquestração após essas datas é o Microsoft Agent Framework, que é baseado em código, ou o Azure Logic Apps, que é visual mas externo ao Foundry. Os agentes em si não são afetados: continuam válidos, com suas instruções e bases de conhecimento. O que precisará ser refeito é a camada de roteamento.

Essa é uma restrição da plataforma, não da solução: hoje não existe no Foundry um caminho de orquestração sem código com longevidade garantida. A arquitetura atual é a melhor opção disponível dentro da restrição de não usar código, e a migração do roteamento deve ser planejada para antes de dezembro de 2026.

11. Evolução Técnica

Etapa	Descrição técnica
Sincronização automatizada	Rotina agendada de extração do ERP, regerando os arquivos de conhecimento ou restabelecendo a consulta direta ao banco
Retorno à consulta em tempo real	Reaproveitamento do Azure SQL e da camada Data API Builder da versão 1.0, quando a exigência de configuração sem código não for mais o critério dominante
Migração do roteamento	Substituição do Workflow por Microsoft Agent Framework ou Azure Logic Apps, antes de 01/12/2026

Etapa	Descrição técnica
Novos domínios	Inclusão de agentes de RH, financeiro ou suporte interno, reaproveitando o mesmo orquestrador
Publicação no Teams	Disponibilização do assistente no ambiente de trabalho da equipe
Controle de acesso	Restrição do projeto e, se necessário, separação de bases por perfil de usuário
Telemetria de negócio	Registro estruturado das consultas para identificar demanda por itens ausentes do catálogo ou sem estoque

12. Referências

- Microsoft Foundry — Agent Service, File Search e Workflows
- Microsoft Foundry — aviso de retirada de Workflows e migração para o Microsoft Agent Framework
- Microsoft Foundry (clássico) — Connected Agents e aviso de retirada
- Power Fx — funções de texto e tabela usadas nas condições do fluxo

Kumulus · Documentação Técnica v2.0 · Rodavale Distribuidora de Autopeças Documento confidencial — reprodução não autorizada